

ANÁLISE DE VIÉS EM MODELOS DE MACHINE LEARNING APLICADOS AO MARKETING BANCÁRIO: UM ESTUDO COMPARATIVO ENTRE DATASETS EUROPEUS

Alessandro Vinicius Rodrigues Costa¹

Resumo:

Este trabalho tem como objetivo analisar o viés em modelos de machine learning voltados ao marketing bancário. Para isso, foram utilizados dois conjuntos de dados públicos do Kaggle: o Bank Marketing Dataset, com dados de campanhas de telemarketing de um banco de Portugal, e o Bank Customer Churn Dataset, com informações de clientes de um banco europeu fictício. Com esses dados foram treinados três modelos de classificação: Regressão Logística, Árvore de Decisão e Random Forest. Para avaliar o desempenho dos modelos foram usadas as métricas de acurácia, F1-Score e ROC-AUC. Já para medir o viés foi utilizado o Disparate Impact, que mostra se o modelo trata grupos demográficos de forma desigual. Os resultados mostraram que mesmo com acurácia alta, os três modelos apresentaram discriminação nos dois datasets: no dataset português o modelo favoreceu clientes mais velhos, enquanto no dataset de churn foram identificados vieses de gênero e de localização geográfica. Com isso, o trabalho conclui que usar só a acurácia para avaliar um modelo não é suficiente quando se trabalha com dados sensíveis, sendo importante incluir métricas de fairness na análise.

Palavras-chave: Machine learning; Viés algorítmico; Marketing Bancário, Fairness, Disparate Impact.

1. Introdução

O uso de machine learning em instituições financeiras tem crescido bastante nos últimos anos. Bancos e fintechs utilizam modelos preditivos para diversas finalidades, como aprovar crédito, identificar fraudes e direcionar campanhas de marketing para clientes com maior chance de aderir a um produto ou serviço.

Apesar dos benefícios, esses modelos podem carregar consigo um problema sério: o viés algorítmico. Isso acontece quando o modelo aprende padrões nos dados históricos que refletem desigualdades já existentes na sociedade, como diferenças de tratamento por idade, gênero ou localização geográfica. Na prática, isso significa que o algoritmo pode tomar decisões prejudiciais para determinados grupos de pessoas sem que isso seja intencional.

¹ Graduando em Desenvolvimento de Software Multiplataforma pela Faculdade de Tecnologia do Estado de São Paulo — FATEC.
RA: 1301392411030. E-mail: alessandro.costa01@aluno.cps.sp.gov.br

Este trabalho busca identificar e comparar os tipos de viés gerados por modelos de machine learning treinados em dois contextos diferentes de marketing bancário. O primeiro contexto é o de aquisição de clientes, representado por dados reais de campanhas de telemarketing de um banco português. O segundo é o de retenção de clientes, representado por um dataset fictício de churn bancário europeu. A comparação entre os dois permite observar como o viés se manifesta de formas distintas dependendo do contexto, dos dados disponíveis e do objetivo do modelo.

2. Referencial Teórico

Machine learning é uma área da inteligência artificial que permite que computadores aprendam padrões a partir de dados históricos e façam previsões ou classificações sem serem explicitamente programados para isso. No contexto bancário, esses modelos são amplamente utilizados para prever comportamentos de clientes, como a adesão a produtos financeiros ou o cancelamento de serviços.

Entre os algoritmos mais utilizados para tarefas de classificação estão a Regressão Logística, a Árvore de Decisão e o Random Forest. A Regressão Logística é um modelo estatístico que estima a probabilidade de um evento ocorrer com base em variáveis de entrada, sendo muito utilizado como modelo base por sua simplicidade e interpretabilidade. A Árvore de Decisão funciona como uma sequência de perguntas encadeadas que divide os dados em grupos cada vez mais específicos até chegar a uma decisão final, sendo fácil de visualizar e interpretar. O Random Forest é uma evolução da Árvore de Decisão que treina várias árvores ao mesmo tempo e combina os resultados, o que geralmente melhora o desempenho e reduz o risco de o modelo decorar os dados de treino.

Para avaliar o desempenho dos modelos, foram utilizados três métricas principais. A acurácia mede a proporção de previsões corretas sobre o total, porém pode ser enganosa quando os dados são desbalanceados. O F1-Score equilibra duas medidas chamadas precisão e recall, sendo mais adequado para situações em que uma das classes é muito menor que a outra. O ROC-AUC mede a capacidade do modelo de separar as classes independentemente do ponto de corte utilizado, sendo amplamente adotado em trabalhos acadêmicos da área.

O viés algorítmico ocorre quando um modelo produz resultados sistematicamente diferentes para grupos distintos de pessoas, como homens e mulheres ou jovens e idosos.

Esse viés geralmente não é intencional e surge porque os dados de treinamento refletem desigualdades históricas que o modelo acaba reproduzindo. Para medir esse tipo de problema, uma das métricas mais utilizadas é o Disparate Impact, que calcula a razão entre a taxa de predição positiva do grupo menos favorecido e a do grupo mais favorecido. Quando esse valor é inferior a 0,8, considera-se que há discriminação, seguindo a chamada regra dos 80%, amplamente utilizada em contextos legais e acadêmicos de fairness em inteligência artificial.

3. Materiais e Métodos

Para o desenvolvimento deste trabalho foram utilizados dois datasets públicos disponíveis na plataforma Kaggle. O primeiro é o Bank Marketing Dataset, originalmente disponibilizado pelo repositório UCI Machine Learning Repository, que contém dados de campanhas de telemarketing realizadas por um banco português entre 2008 e 2013, período marcado pela crise econômica europeia. O objetivo do dataset é prever se o cliente vai aderir a um depósito a prazo, representado pela variável alvo "y". Ao todo são 41.188 registros e 21 colunas, incluindo informações como idade, profissão, estado civil, nível de educação, histórico de contato e indicadores macroeconômicos como taxa de emprego e índice de confiança do consumidor.

O segundo dataset é o Bank Customer Churn Dataset, composto por 10.000 registros de clientes de um banco fictício europeu com presença na França, Alemanha e Espanha. O objetivo é prever se o cliente vai abandonar o banco, representado pela variável alvo "Exited". As colunas disponíveis incluem score de crédito, localização geográfica, gênero, idade, tempo como cliente, saldo em conta, número de produtos contratados e salário estimado.

No pré-processamento do Bank Marketing Dataset foi removida a coluna "duration", que representa a duração da ligação telefônica e só é conhecida após o contato ser realizado, o que causaria vazamento de dados e tornaria o modelo inútil na prática. No dataset de churn foram removidas as colunas de identificação do cliente, como número de linha, ID e sobrenome, por não contribuírem para o aprendizado do modelo. Em seguida, as variáveis categóricas de ambos os datasets foram convertidas em formato numérico por meio da técnica de One-Hot Encoding, que cria uma coluna binária para cada categoria, evitando que o modelo intérprete as categorias como hierarquias

numéricas. Após a codificação, o Bank Marketing Dataset passou de 20 para 63 colunas, enquanto o dataset de churn passou de 11 para 13.

Os dados foram divididos em 80% para treino e 20% para teste, com estratificação pela variável alvo para garantir que a proporção entre as classes fosse mantida em ambas as partições.


Por fim, os dados foram normalizados com o StandardScaler, transformando todas as variáveis para uma escala com média zero e desvio padrão igual a um, o que melhora o desempenho de modelos sensíveis à escala como a Regressão Logística.

Foram treinados três modelos de classificação em cada dataset: Regressão Logística com máximo de 1000 iterações, Árvore de Decisão com profundidade máxima de 5 níveis e Random Forest com 100 árvores. A análise de viés foi realizada com base nas predições do Random Forest, por ser o modelo com melhor desempenho geral, utilizando o cálculo do Disparate Impact para os grupos de faixa etária no dataset português e de gênero e geografia no dataset de churn.

4. Resultados e Discussão

A análise exploratória dos dados revelou um desbalanceamento significativo nas variáveis alvo dos dois datasets. No Bank Marketing Dataset, 88,7% dos clientes não aderiram ao depósito a prazo, contra apenas 11,3% que aderiram. No dataset de churn, 79,6% dos clientes permaneceram no banco enquanto 20,4% abandonaram o serviço. Esse desbalanceamento, ilustrado na Figura 1, é um fator determinante para o comportamento dos modelos e para a geração de viés nas predições.


Figura 1 — Distribuição das classes nos dois datasets.



Fonte: Elaborado pelo autor (2025).

A análise das variáveis sensíveis em relação à variável alvo, apresentada na Figura 2, revelou padrões importantes. No dataset português, clientes com 60 anos ou mais apresentaram taxa de adesão ao depósito próxima de 40%, enquanto clientes entre 41 e 50 anos tiveram taxa de apenas 10%. No dataset de churn, mulheres apresentaram taxa de abandono de 25% contra 17% dos homens, e clientes alemães apresentaram taxa de churn de aproximadamente 32%, contra 16% de franceses e espanhóis.

Figura 2 — Relação entre variáveis sensíveis e variável alvo.



Fonte: Elaborado pelo autor (2025).

Os três modelos foram avaliados com as métricas de acurácia, F1-Score e ROC-AUC, cujos resultados estão apresentados na Tabela 1.

Tabela 1 — Desempenho dos modelos nos dois datasets


Dataset	Modelo	Acurácia	F1-Score	ROC-AUC
Portugal	Regressão Logística	0,901	0,337	0,801
Portugal	Árvore de Decisão	0,903	0,365	0,791
Portugal	Random Forest	0,897	0,398	0,785
Churn	Regressão Logística	0,808	0,284	0,775
Churn	Árvore de Decisão	0,856	0,531	0,842
Churn	Random Forest	0,859	0,569	0,852

Fonte: elaborado pelo autor (2025).

Os resultados mostram que no dataset português todos os modelos atingiram acurácia acima de 89%, porém com F1-Score muito baixo, variando entre 0,337 e 0,398. Isso ocorre porque o forte desbalanceamento das classes faz com que os modelos tendam a classificar a maioria dos clientes como "não vai aderir", acertando com frequência, mas sendo incapazes de identificar corretamente os clientes que realmente adeririam ao produto. No dataset de churn os modelos apresentaram desempenho mais equilibrado, com F1-Score entre 0,284 e 0,569, sendo o Random Forest o modelo com melhor resultado nos dois datasets.

A análise de viés por meio do Disparate Impact confirmou a presença de discriminação nos dois datasets. No dataset português, clientes entre 41 e 50 anos receberam predição positiva em apenas 3,2% dos casos, contra 39,7% dos clientes com 60 anos ou mais, resultando em um Disparate Impact de 0,081. No dataset de churn, homens tiveram taxa de predição de saída de 9,5% contra 15,6% das mulheres, com Disparate Impact de 0,609. Já em relação à geografia, clientes franceses tiveram taxa de 8,1% contra 24,2% dos alemães, resultando em Disparate Impact de 0,335. Os três valores estão muito abaixo do limite de 0,8 estabelecido pela regra dos 80%, indicando discriminação significativa em todos os casos, conforme ilustrado na Figura 3.

Figura 3 — Disparate Impact por grupo demográfico.



Fonte: elaborado pelo autor (2025).

Esses resultados demonstram que o viés algorítmico se manifesta de formas distintas dependendo do contexto dos dados. No dataset português o viés é fortemente influenciado pelo contexto econômico da crise de 2008, que afetou de maneira diferente cada faixa etária. Já no dataset de churn o viés reflete desigualdades estruturais de gênero e diferenças culturais entre países europeus. Em ambos os casos, o uso exclusivo da acurácia como métrica de avaliação levaria a conclusões equivocadas sobre a qualidade dos modelos.

5. Conclusão

Este trabalho analisou o viés algorítmico em modelos de machine learning aplicados ao marketing bancário utilizando dois datasets com contextos distintos. Os resultados confirmaram que mesmo com acurácia elevada, os modelos apresentaram discriminação significativa em ambos os casos, com viés de idade no dataset português e viés de gênero e geográfico no dataset de churn.

Conclui-se que a acurácia isolada não é suficiente para avaliar modelos aplicados a contextos sensíveis, sendo necessário incluir métricas de fairness como o Disparate Impact. Para trabalhos futuros, sugere-se aplicar técnicas de mitigação de viés como o rebalanceamento de classes com SMOTE, avaliando se é possível reduzir a discriminação sem comprometer o desempenho dos modelos.

Referências

MORO, S.; CORTEZ, P.; RITA, P. A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, v. 62, p. 22-31, 2014.

KAGGLE. Bank Marketing Dataset. Disponível em:

<https://www.kaggle.com/datasets/henriqueyamahata/bank-marketing>.

Acesso em: maio 2025.

KAGGLE. Predicting Churn for Bank Customers. Disponível em:

<https://www.kaggle.com/datasets/adammaus/predicting-churn-for-bank-customers>.

Acesso em: maio 2025.

FELDMAN, M. et al. Certifying and removing disparate impact. In: *PROCEEDINGS OF THE ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*, 21., 2015, Sydney. Anais... New York: ACM, 2015. p. 259-268.

GÉRON, A. *Mãos à obra: aprendizado de máquina com Scikit-Learn e TensorFlow*. 2. ed. Rio de Janeiro: Alta Books, 2019.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.